



UNIVERSIDADE ESTADUAL DE MARINGÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE INFORMÁTICA

GABRIEL SARAIVA DE GOUVEIA	RA 129145
OLGA MARIA DOS SANTOS	RA 130002
YASSER FARID PEREIRA	RA 129706

TRABALHO 01: Análise de Crédito usando Redes Bayesianas

MARINGÁ
Abril/2026

1. Descrição do Problema

O crédito é um dos pilares do sistema financeiro moderno, e a avaliação correta do risco de concessão de crédito impacta tanto instituições financeiras quanto consumidores. O problema modelado neste trabalho consiste em classificar o score de crédito de um cliente em três categorias: bom, regular e ruim a partir de variáveis financeiras.

Para isso, foi construída manualmente uma Rede Bayesiana Discreta com 10 variáveis (nós) e 12 relações de dependência probabilística (arestas), utilizando a biblioteca pgmpy em Python.

2. Descrição do Dataset

O dataset utilizado é o Credit Score Classification, disponível no Kaggle (parisrohan/credit-score-classification). O conjunto contém registros mensais de clientes de uma instituição financeira fictícia, totalizando 100.000 linhas e 28 colunas no arquivo de treino. Após a limpeza, restaram 65.438 registros válidos.

Distribuição da variável alvo Credit_Score:

Classe	Qtd. de Registros	Proporção
Standard	34.971	53,4%
Poor	18.470	28,2%
Good	11.997	18,3%
Total	65.438	100%

Tabela 1 - Distribuição da variável alvo Credit_Score após limpeza.

Das 28 colunas originais, foram selecionadas 10 variáveis com maior relevância para a modelagem, sendo elas Age, Annual_Income, Num_Bank_Accounts, Num_Credit_Card, Interest_Rate, Num_of_Loan, Delay_from_due_date, Outstanding_Debt, Credit_Mix e Credit_Score.

3. Estrutura da Rede Bayesiana

A estrutura foi definida manualmente, sem uso de qualquer algoritmo automático. A rede possui 10 nós e 12 arestas direcionadas, organizadas em três camadas funcionais:

Camada de Entrada (6 nós): Age, Income, Num_Bank_Accounts, Num_Credit_Card, Interest_Rate e Num_of_Loan. Variáveis exógenas, sem pais na rede.

Camada Intermediária (3 nós): Delay_from_due_date, Outstanding_Debt e Credit_Mix. Recebem influências das variáveis de entrada e propagam seus efeitos ao nó alvo.

Camada de Saída (1 nó): Credit_Score. Variável alvo, influenciada diretamente por Age, Income, Num_Bank_Accounts, Delay_from_due_date, Outstanding_Debt e Credit_Mix.




Figura 1 - Estrutura gráfica da Rede Bayesiana modelada (gerada pelo notebook).

As 12 arestas e suas justificativas de domínio são:

Aresta	Justificativa
Income → Outstanding_Debt	Renda maior reduz a dívida pendente
Income → Credit_Score	Renda é fator direto na avaliação de crédito
Num_Credit_Card → Outstanding_Debt	Mais cartões tendem a aumentar dívidas acumuladas
Num_Credit_Card → Credit_Mix	Quantidade de cartões diversifica o mix de crédito
Interest_Rate → Outstanding_Debt	Taxas maiores elevam o saldo devedor
Num_of_Loan → Outstanding_Debt	Mais empréstimos elevam a dívida total
Num_of_Loan → Delay_from_due_date	Mais empréstimos aumentam chance de atrasos

Age → Credit_Score	Clientes mais velhos tendem a ter histórico maior
Num_Bank_Accounts → Credit_Score	Múltiplas contas indicam relacionamento bancário diverso
Delay_from_due_date → Credit_Score	Atrasos impactam negativamente o score de crédito
Outstanding_Debt → Credit_Score	Dívida alta é fator de risco direto para score ruim
Credit_Mix → Credit_Score	Mix diversificado de crédito melhora o score

Tabela 3 - Arestas da rede e justificativas baseadas em conhecimento de domínio.

4. Resultados e Análises

As Tabelas de Probabilidade Condicional (CPDs) foram estimadas pelo método de Máxima Verossimilhança sobre os 65.438 registros válidos. As CPDs capturam como cada variável se distribui condicionalmente a seus nós-pais. Por exemplo, a CPD de Outstanding_Debt é condicionada à Income, Num_Credit_Card, Interest_Rate e Num_of_Loan, refletindo como diferentes fatores combinam-se para determinar o nível de endividamento.

Foram realizadas 5 consultas de inferência usando o algoritmo de Eliminação de Variáveis (VariableElimination). Os resultados das três principais consultas sobre o Credit_Score estão apresentados abaixo:




Figura 2 - Distribuição de probabilidade do Credit_Score para os três perfis analisados.

Os resultados evidenciam a capacidade discriminatória da rede: para o perfil de risco alto, a probabilidade de Poor é quase três vezes maior do que para o perfil de baixo risco (41,16% vs. 14,82%). Quando o cliente possui Credit_Mix=Good e dívida baixa, a probabilidade de score Good sobe para 44,66%, consideravelmente acima da média de 18,3% observada no dataset.

A análise de independências locais (d-separação) confirmou a coerência estrutural da rede. Os principais resultados foram:

- Age é independente de todas as demais variáveis de entrada (sem pais na rede).
- Credit_Mix é independente de todas as variáveis, exceto Num_Credit_Card.
- Delay_from_due_date é condicionalmente independente das demais, dado Num_of_Loan.
- Outstanding_Debt é independente de Age, Credit_Mix e Num_Bank_Accounts, dado seus pais diretos (Income, Interest_Rate, Num_Credit_Card, Num_of_Loan).
- Credit_Score é condicionalmente independente de Interest_Rate, Num_Credit_Card e Num_of_Loan, dado o conjunto de seus pais diretos na rede.

5. Conclusões

A Rede Bayesiana modelada demonstrou-se uma ferramenta eficaz para representar e quantificar as relações de dependência entre variáveis do domínio financeiro. A estrutura manual permitiu incorporar conhecimento especializado sobre concessão de crédito, tornando o modelo interpretável e justificável do ponto de vista do negócio.

Os resultados das inferências confirmam intuições do domínio: atrasos nos pagamentos e dívidas elevadas são os principais fatores de degradação do score de crédito, enquanto um mix de crédito diversificado e dívida baixa eleva significativamente a probabilidade de score Good. A análise de independências condicionais validou a coerência estrutural da rede, demonstrando que as relações modeladas refletem corretamente as dependências presentes nos dados.

Referências Bibliográficas

PEARL, J. Probabilistic Reasoning in Intelligent Systems. Morgan Kaufmann, 1988.

PGMPY DEVELOPERS. pgmpy: Python Library for Probabilistic Graphical Models. Disponível em: <https://pgmpy.org/>. Acesso em: abr. 2026.

ROHAN, P. Credit Score Classification Dataset. Kaggle, 2022. Disponível em: <https://www.kaggle.com/datasets/parisrohan/credit-score-classification>.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2020.